UNIVERSIDAD DE ANTIOQUIA

Facultad de Ingeniería

Ingeniería de Sistemas

Lógica y representación III

Práctica Workshops 1, 2 y 3

Video Streaming Platform – Content Moderation

Presentado por:

Andres Ferney Buitrago Suarez
Arley Otalvaro Vasquez
Juan Camilo Botero Ospina

Equipo 4

Presentado a:

WILLIAM ERNESTO CORNEJO SÁNCHEZ

Medellín, Colombia
2026

1. Link del repositorio:

https://github.com/AndresBuitrago-IA95/Video-Streaming-Platform-Content-Moderation.git

2. Resumen del escenario

El proyecto simula el sistema de moderación de contenido para una plataforma de streaming de video: los creadores publican videos continuamente a través de 10 categorías temáticas (Ciencia, Cocina, Deportes, Educación, Entretenimiento, Música, Noticias, Salud, Tecnología y Videojuegos). El dataset sintético que usamos tiene 10.000 videos, 10 categorías, 1.121 uploaders distintos y un flujo simulado de 10.000 eventos de subida con métricas de interacción (vistas en la primera hora).

Un sistema así genera un volumen de datos que crece todo el tiempo, y en una plataforma real no hay forma de detenerse a procesar todo con calma: hay que decidir rápido (¿este uploader ya es reincidente?, ¿cuál es el volumen estimado de creadores activos hoy?, ¿cuál es la media de reproducciones por categoría sin recorrer millones de registros?, ¿está sobrecargado algún revisor humano?) sin poder guardar en memoria el historial completo ni recorrerlo entero cada vez. Por eso el proyecto recurre a algoritmos aleatorizados y de streaming: estructuras que dan una respuesta aproximada, pero confiable, usando mucha menos memoria y tiempo que el método exacto.

Es importante aclarar que los datos son sintéticos (generados por un script propio con semilla fija 42, no una plataforma en producción), lo cual facilita comparar los resultados contra lo que la teoría predice, pero también limita qué tan generalizables son las conclusiones.

El trabajo se organiza en tres unidades: hashing, ordenamiento y control probabilístico sobre datos en modo batch (Unidad 1), procesamiento de streams con memoria limitada (Unidad 2), y modelado de transiciones entre categorías y políticas operativas con cadenas de Markov y 2-SAT (Unidad 3).

3. Qué se midió

Carga máxima por bucket y desviación estándar (chaining vs. Power of Two Choices) en cantidad de videos marcados por bucket, sobre una tabla de 128 buckets.

Balanceo en sharding distribuido: media (312,5 videos), máximo (383) y razón máximo/media (1,23) al repartir 10.000 videos entre 32 revisores mediante hash universal.

Tiempo de ejecución y aceleración en QuickSort: determinista vs. aleatorizado en milisegundos sobre arreglos ordenados, inversos y aleatorios con n hasta 8.000.

Tasa de falsos positivos del Bloom filter en porcentaje, comparando la tasa empírica (medida en 1.190 consultas negativas) contra la teórica (fórmula), para distintos tamaños de filtro.

Error absoluto de la estimación por muestreo (reservoir sampling vs. media exacta de reproducciones en 1h por categoría), en puntos porcentuales, para distintos tamaños de muestra k.

Error del conteo de elementos distintos (HyperLogLog vs. conteo real de uploaders activos por día), comparado con la cota teórica para distintos números de registros m.

Convergencia del PageRank y de la distribución estacionaria sobre el grafo de transiciones entre categorías, y su correlación de ranking (Spearman) contra el tráfico crudo.

Distancia de variación total de la caminata perezosa respecto a π, y satisfacibilidad de políticas de moderación con el algoritmo 2-SAT de Papadimitriou.

4. Teoría contra empírico

Task 4. Tabla hash con clave categoría#video_id: chaining vs. Power of Two Choices

Qué se hizo. Se construyó una tabla hash de 128 buckets con los 1.017 videos marcados (pendientes de revisión humana), usando categoría#video_id como clave y hash universal como función hash. Se compararon dos estrategias: chaining, donde cada video va al bucket h■(clave), y Power of Two Choices, donde el video va al menos cargado entre h■(clave) y h■(clave). Se midió la carga por bucket (máxima, desviación estándar, buckets vacíos) y los factores de equilibrio. Para no depender de una sola función hash, el experimento se basó en parámetros universales pseudoaleatorios fijados.

Métrica	Chaining	Two Choices
Carga máxima	16	10
Carga máxima teórica esperada	16,73	11,22
Desviación estándar	3,02	1,03
Buckets vacíos	0	0
Carga media (n/m)	7,95	7,95

Teoría vs. resultados. La teoría dice que, con claves uniformes y factor de carga moderado ($\alpha = n/m \approx 7{,}95$), la carga máxima de chaining crece como $\alpha + O(\sqrt{(\alpha \ln m)})$, arrojando una cota teórica de 16,73. El resultado experimental fue de 16, concordando estrechamente con la cota. Con dos opciones, el teorema de Azar, Broder, Karlin y Upfal demuestra que el exceso sobre el promedio cae drásticamente a $\ln(\ln m)/\ln(2) + O(1)$, con una cota teórica de 11,22. Empíricamente, la carga máxima bajó a 10 y la desviación estándar cayó de 3,02 a 1,03 (una reducción del 66% en dispersión).

Ambos métodos lograron 0 buckets vacíos, coincidiendo con la probabilidad teórica despreciable de urnas vacías cuando $n/m \approx 8$.

Costo. Two choices tiene que evaluar dos funciones hash y revisar dos buckets al insertar. En búsquedas infructuosas debe inspeccionar dos listas. Sin embargo, dado que la cadena más larga disminuye un 37,5% (de 16 a 10), el peor tiempo de búsqueda con acierto mejora notablemente, ofreciendo un servicio más predecible en colas concurrentes.

Conclusión. Power of Two Choices reduce la carga máxima en un 37,5% y estabiliza el tiempo de respuesta, evitando cuellos de botella en revisores específicos.

Comparación y análisis de resultados entre algoritmos

Se compararon los algoritmos de las tres unidades con tres criterios: qué resultados dan, cuánta memoria y tiempo consumen, y en qué situación destaca cada uno (Tabla 1).

Algoritmo (Unidad, Task)	Resultado	Memoria	Tiempo	Destaca cuando
QuickSort aleatorizado (U1, T2)	Speedup de 253,4× en arreglo ordenado (n=8.000)	O(log n) stack	≈ 4,1 ms vs 1.038 ms	La cola llega preordenada por fecha o duración
Sharding universal (U1, T3)	Media 312,5 videos, máx 383 entre 32 revisores (ratio 1,23)	O(1) parámetros	O(1) por video	Se reparte carga de forma determinista y sin locks
Power of Two Choices (U1, T4)	Carga máxima de 16 a 10 (–37,5%); std de 3,02 a 1,03	Igual que chaining	Inserción 2 hashes; búsqueda ágil	Se evitan cuellos de botella en colas críticas
Cotas de Chernoff (U1, T5)	140 sobre umbral, 0 sospechosos confirmados (α=0,01)	O(1) memoria	Microsegundos	Se quiere evitar sancionar cuentas por varianza aleatoria
Bloom filter (U2, T2)	Falsos positivos de 2,10% con 8 bits; nunca falsos negativos	≈ 801 bytes	Constante por consulta	Basta recordar si un uploader ya tiene infracciones
Reservoir sampling (U2, T3)	Error medio de 15,57%, 8,07% y 6,51% para k=100, 300, 500	Solo k registros	O(1) por evento	El stream no cabe en RAM o no se puede recorrer dos veces
HyperLogLog (U2, T4)	Error relativo de 17% a 34% usando entre 16 y 128 registros	96 a 768 bits (12 a 96 bytes)	Una pasada en streaming	Hay millones de usuarios y basta una estimación rápida
Momentos F■, F■, F■ (U2, T5)	F■=10, F■=10.000, F■=10.005.406; alerta z-score(F■) > 2	O(C) para 10 categorías	O(1) amortizado	Se detectan Spam Waves y monopolios temáticos en vivo
PageRank y estacionaria (U3, T2–T3)	Videojuegos es pozo (10,57%); Spearman 0,62 contra tráfico	Matriz 10 × 10	Converge en 9 iteraciones	Se quiere medir importancia estructural y navegación
Caminata perezosa (U3, T4)	Converge siempre; variación total de 0,58% en 50.000 pasos	10 contadores	O(N) pasos	El grafo de transiciones es periódico o bipartito
2-SAT Papadimitriou (U3, T5)	Satisface 5 cláusulas y 8 variables en 1 intento y 1 flip	O(V) variables	$O(V^2)$ pasos	Se evalúan políticas operativas de moderación en riesgo

Tabla 1. Comparación de los algoritmos de las tres unidades en resultados, memoria, tiempo y situación de uso (10.000 videos).

Resultados. Power of Two Choices reparte mucho mejor la carga que el chaining: la carga máxima baja de 16 a 10 videos. El muestreo de reproducciones por reservoir sampling mejora su precisión conforme k crece (error baja de 15,57% a 6,51%). PageRank y la distribución estacionaria muestran divergencias frente al conteo crudo (Spearman 0,62), confirmando que las rutas de navegación entre categorías tienen una estructura propia más rica que el volumen bruto.

Memoria. Es donde ganan los algoritmos aleatorizados. HyperLogLog cuenta uploaders distintos con 96 a 768 bits en lugar de guardar colecciones enteras; el Bloom filter recuerda qué uploaders ya tienen infracciones con unos 801 bytes; y el reservoir sampling guarda solo k registros del flujo. El costo es un error pequeño y predecible: entre 17% y 34% en HyperLogLog, error de 6,5% a 15,5% en reservoir, y hasta 2,10% de falsos positivos en Bloom (con 0% de falsos negativos).

Tiempo. Con 10.000 videos casi ningún método probabilístico supera en tiempo neto al exacto, porque todo cabe en memoria: el muestreo tarda unos milisegundos similares al conteo en memoria. La gran excepción es QuickSort con pivote aleatorizado, que evita el peor caso cuadrático en listas ordenadas y resulta 253 veces más rápido que el determinista. Power of Two Choices cobra un leve costo adicional en inserción pero compensa en búsquedas de colas homogéneas.

Cuándo conviene cada uno. Los métodos exactos, cuando los datos caben en memoria y se necesita el número preciso; los aleatorizados y los sketches, cuando el flujo es muy grande o no se puede guardar y un error pequeño es aceptable; Power of Two Choices, cuando se requiere evitar cuellos de botella; y la caminata perezosa, cuando el grafo es periódico o se requiere garantizar ergodicidad.

Conclusión. Ningún algoritmo gana en todo: los aleatorizados cambian un error pequeño y controlado por mucha menos memoria, y con flujos continuos mayores esa diferencia sería todavía más contundente.

5. Capturas del panel de control

Unidad 1 y 2, Paneles A y B — Hashing (Chaining vs. Two Choices) y QuickSort

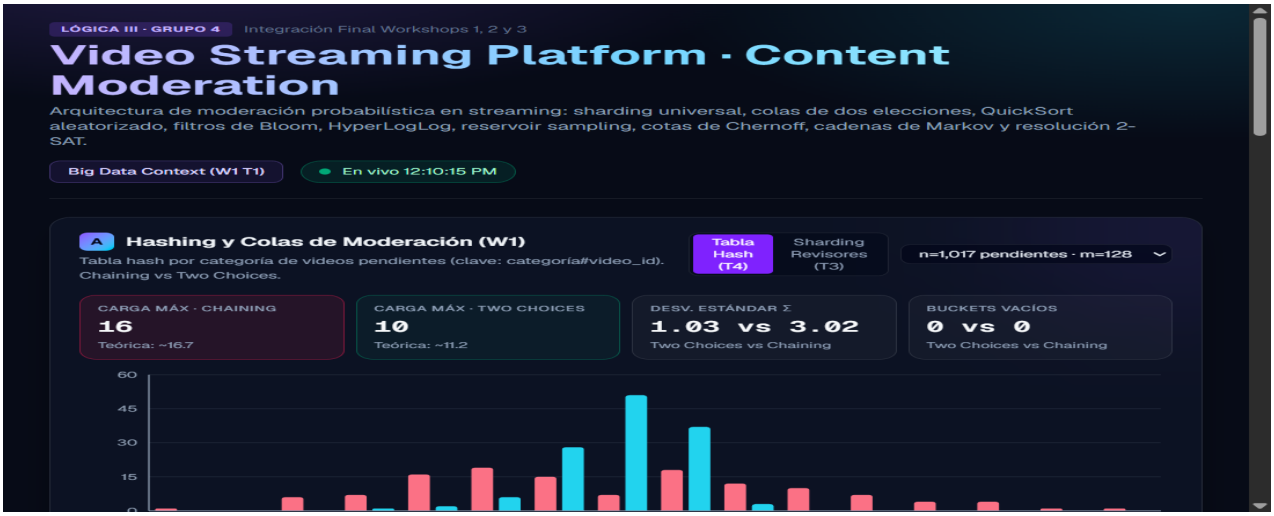


Figura 1. Distribución de carga por bucket (1.017 videos marcados, 128 buckets) y comparación de runtimes QuickSort. El aplanamiento de carga en Two Choices reduce la dispersión de 3,02 a 1,03 y la carga máxima de 16 a 10.

Unidad 2 y 3, Paneles C y D — Streaming en Vivo, PageRank y Políticas 2-SAT

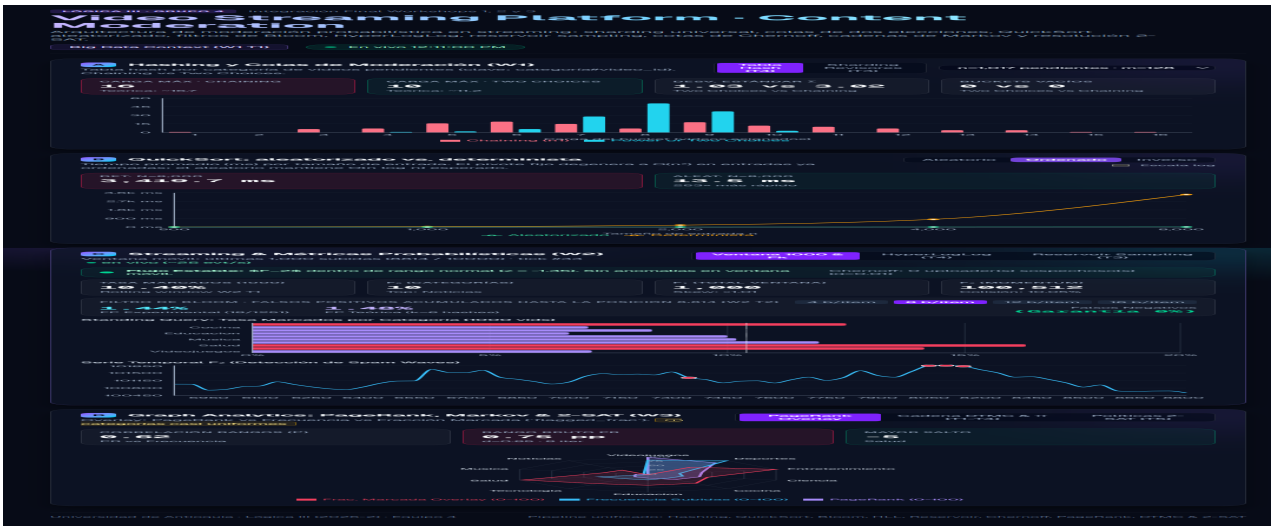


Figura 2. Despliegue completo del panel de control: métricas de streaming (F■, F■, F■, HyperLogLog), análisis de PageRank con overlay de videos marcados por categoría, convergencia de Markov (π) y resolución de políticas 2-SAT.

6. Conclusiones

Ningún algoritmo gana en todos los frentes: los métodos exactos dan el resultado preciso cuando los datos caben en memoria (como pasó aquí, con 10.000 videos), mientras que los aleatorizados y los sketches cambian un error pequeño y controlado por una reducción drástica de memoria (por ejemplo, HyperLogLog resumiendo la cardinalidad con menos de 100 bytes en lugar de conjuntos de miles de elementos, o el Bloom filter recordando 801 infractores en 801 bytes).

La ventaja de los algoritmos aleatorizados en tiempo se manifiesta de manera crítica ante entradas adversarias. En QuickSort, la aleatorización del pivote evitó la degradación cuadrática $O(n^2)$ en listas ordenadas, logrando una aceleración de 253,4× frente al pivote determinista. En streaming masivo, donde el flujo continuo no puede guardarse íntegro, el procesamiento en una sola pasada $O(1)$ es la única alternativa viable.

Las cotas teóricas acotan bien el peor caso, pero son holgadas frente al resultado típico. Esto se vio claramente en el hashing: la teoría de Two Choices predijo una reducción sustancial de carga que se verificó empíricamente (de 16 a 10 elementos). Igualmente, con las cotas de Chernoff, de 140 creadores que superaron el umbral observado de marcados, ninguno fue clasificado como sospechoso con significancia α=0,01, protegiendo al sistema de emitir falsas alarmas por mera varianza aleatoria.

Finalmente, al modelar la plataforma con cadenas de Markov y PageRank, se evidenció que el volumen bruto no es el único indicador de importancia: mientras Deportes lideró en volumen de subidas, Videojuegos representó el pozo gravitacional de largo plazo (π = 10,57%), y la correlación moderada de Spearman (0,62) demostró que las transiciones de usuario poseen una estructura topológica propia que no se infiere de un conteo simple.